

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ - ĐHQGHN
VIỆN TRÍ TUỆ NHÂN TẠO



BÁO CÁO MÔN HỌC KỸ THUẬT VÀ CÔNG
NGHỆ DỮ LIỆU LỚN

ĐỀ TÀI:
HỆ THỐNG PHÂN TÍCH CẢM
XÚC TIN TỨC TÀI CHÍNH THỜI
GIAN THỰC

Sinh viên thực hiện:

Hà Đức Dũng - 24022300

HÀ NỘI - 2026

MỞ ĐẦU

Sự phát triển của thị trường tài chính toàn cầu nói chung và thị trường chứng khoán Việt Nam nói riêng đặt ra những thách thức lớn trong việc nắm bắt thông tin vĩ mô. Khác với các chỉ số kỹ thuật có cấu trúc như giá hay khối lượng giao dịch vốn dễ định lượng, dòng chảy tin tức từ các phương tiện truyền thông chính thống đại diện cho một nguồn tài nguyên dữ liệu phi cấu trúc khổng lồ, chứa đựng tâm lý và kỳ vọng của toàn thị trường. Việc xử lý thủ công nguồn thông tin này là hoàn toàn bất khả thi trong kỷ nguyên thông tin số có tốc độ và khối lượng gia tăng không ngừng.

Để giải quyết bài toán cốt lõi này, dự án xây dựng một hệ thống phân tán toàn diện áp dụng kiến trúc *Lambda Architecture*. Hệ thống không chỉ có khả năng thu thập, tiền xử lý và phân tích sắc thái cảm xúc tin tức tiếng Việt dựa trên mô hình học sâu Transformer (PhoBERT) theo thời gian thực, mà còn tích hợp lớp xử lý lô phân tán (Batch Layer) bằng Apache Spark phục vụ phân tích thống kê lịch sử dài hạn. Toàn bộ chỉ số cảm xúc sau đó được đối chiếu trực tiếp với biến động thực tế của chỉ số VN-Index, cung cấp một góc nhìn trực quan định lượng sâu sắc về mối tương quan mật thiết giữa truyền thông vĩ mô và xu hướng dòng tiền thị trường.

Mục lục

MỞ ĐẦU	1
Mục lục	2
1 CHƯƠNG 1: TỔNG QUAN	3
1.1 Tính cấp thiết và Tầm quan trọng đề tài	3
1.2 Mục tiêu cụ thể của dự án	3
1.3 Phạm vi dự án	3
2 CHƯƠNG 2: PHƯƠNG PHÁP	5
2.1 Kiến trúc hệ thống toàn cục (Lambda Architecture)	5
2.2 Chi tiết các công nghệ cốt lõi lựa chọn	5
2.2.1 Apache Kafka Cluster	5
2.2.2 Apache Spark Structured Streaming	6
2.2.3 MongoDB NoSQL Serving Store	6
2.3 Quy trình thu thập, xử lý dữ liệu và Thiết kế tính Lũy đẳng	6
2.3.1 Kỹ thuật tiền xử lý dữ liệu văn bản	6
2.3.2 Cơ chế Persistent Cache Warm-up chống trùng lặp đầu nguồn . . .	6
2.4 Phân tích cảm xúc bằng Mô hình Học sâu Transformer (PhoBERT)	7
3 CHƯƠNG 3: KẾT QUẢ VÀ HƯỚNG PHÁT TRIỂN	8
3.1 Giao diện Dashboard trực quan hóa tổng hợp	8
3.2 Thách thức kỹ thuật đã giải quyết	9
3.3 Hướng phát triển đề tài	9
Tài liệu	10

1 CHƯƠNG 1: TỔNG QUAN

1.1 Tính cấp thiết và Tầm quan trọng đề tài

Dự đoán biến động tài chính luôn là mục tiêu tối thượng giúp các tổ chức và cá nhân tối ưu hóa dòng vốn, giảm thiểu rủi ro hệ thống. Tuy nhiên, thị trường thường phản ứng cực kỳ nhạy cảm với các sự kiện kinh tế chính trị được phát đi từ báo chí. Một tin tức tiêu cực về lạm phát hay các vụ án kinh tế có thể châm ngòi cho làn sóng bán tháo chỉ trong vài phút.

Xử lý các thách thức này trong môi trường dữ liệu lớn đặt ra hai yêu cầu bắt buộc: xử lý tốc độ cao đối với các luồng tin trực tuyến (Velocity) và khả năng phân tích bao quát lượng dữ liệu lịch sử tích lũy khổng lồ (Volume). Việc ứng dụng các công cụ Big Data phân tán giúp chuẩn hóa, phân loại cảm xúc tự động và lưu trữ khoa học, biến các văn bản báo chí định tính thành chỉ số định lượng có giá trị thực tiễn cao cho hệ thống quản trị rủi ro.

1.2 Mục tiêu cụ thể của dự án

Dự án được triển khai nhằm hiện thực hóa các mục tiêu kỹ thuật thực chiến sau:

- **Xây dựng Pipeline thu thập tự động đa nguồn:** Thiết lập module Scraper đa luồng, tự động hóa việc quét dọn và đồng bộ tin tức tài chính từ 5 cơ quan báo chí lớn của Việt Nam (VnExpress, Dân Trí, Tuổi Trẻ, Thanh Niên, Vietnamnet) theo chu kỳ.
- **Nhúng mô hình AI ngôn ngữ lớn vào luồng phân tán:** Tích hợp và cấu hình mô hình PhoBERT tối ưu hóa cho tiếng Việt vào lõi tính toán của Apache Spark để thực hiện gán nhãn sắc thái thời gian thực.
- **Thiết kế hệ thống chống trùng lặp lũy đẳng (Idempotency):** Giải quyết triệt để bài toán trùng lặp dữ liệu thô đầu nguồn từ RSS khi hệ thống tắt bật hoặc gặp sự cố ngắt kết nối đột ngột.
- **Xây dựng Dashboard Real-time tương tác cao:** Phát triển giao diện web kết hợp gọi API dữ liệu thị trường trực tiếp để tìm ra điểm tương quan trực quan giữa dòng thời gian tin tức và chỉ số chứng khoán VN-Index.

1.3 Phạm vi dự án

Phạm vi nghiên cứu và triển khai của đề tài được giới hạn rõ ràng nhằm tối ưu hóa tính khả thi:

- **Các thành phần bao gồm:** Thu thập tin tức tài chính ngắn hạn (tin vĩ mô, doanh nghiệp, dòng tiền); tiền xử lý làm sạch mã font HTML; phân loại sắc thái thành 3 nhãn cố định (POS - Tích cực, NEG - Tiêu cực, NEU - Trung lập); lưu trữ NoSQL; tính toán chỉ số lô theo ngày; trực quan hóa tương quan VN-Index trong biên độ 30 ngày.
- **Các thành phần loại trừ:** Dự án không đi sâu vào việc tinh chỉnh trọng số (fine-tuning) hay huấn luyện lại từ đầu cấu trúc mạng Transformer; không xét đến các yếu tố kỹ thuật nội tại của doanh nghiệp (báo cáo tài chính) và không mở rộng ra các thị trường tài sản số khác như ngoại hối hay tiền mã hóa.

2 CHƯƠNG 2: PHƯƠNG PHÁP

2.1 Kiến trúc hệ thống toàn cục (Lambda Architecture)

Hệ thống được thiết kế dựa trên mô hình kiến trúc kinh điển Lambda Architecture nhằm dung hòa hai bài toán: xử lý tức thời dữ liệu mới đến và đảm bảo tính chính xác toàn vẹn của dữ liệu lịch sử dài hạn. Kiến trúc được chia tách mạch lạc thành 4 tầng chức năng cốt lõi độc lập:

- **Ingestion Layer (Tầng thu thập):** Đóng vai trò là cửa ngõ đầu vào. Luồng dữ liệu thô từ các bot Scraper được đẩy thẳng vào Apache Kafka dưới dạng các bản tin JSON. Sự hiện diện của Kafka giúp tách biệt hoàn toàn tầng thu thập tin tức và tầng phân tích xử lý AI, bảo vệ hệ thống khỏi hiện tượng nghẽn cổ chai khi tin tức dâng trào đột biến.
- **Speed Layer (Tầng thời gian thực):** Trách nhiệm xử lý luồng thuộc về Apache Spark Streaming. Spark liên tục bóc tách dữ liệu từ các phân vùng của Kafka thông qua cơ chế micro-batch. Các bản tin văn bản được đưa trực tiếp vào mô hình AI PhoBERT chạy inference trực tuyến để phân loại sắc thái, kết quả được ghi nhận tức thì xuống cơ sở dữ liệu.
- **Batch Layer (Tầng xử lý lô):** Vận hành hoàn toàn song song và độc lập với Speed Layer. Định kỳ, một tiến trình PySpark xử lý lô độc lập sẽ truy vấn toàn bộ kho dữ liệu thô tích lũy tại Datalake, tiến hành tái định hình cấu trúc dữ liệu (Data Reshaping) bằng các hàm biến đổi phân tán chuyên sâu để kết xuất các báo cáo mật độ cảm xúc vĩ mô cô đặc theo ngày.
- **Serving Layer (Tầng dịch vụ trực quan):** Đóng vai trò là tầng phân phối thông tin cuối cùng đến người dùng. Cơ sở dữ liệu NoSQL lưu trữ cả hai luồng chế độ xem (*Real-time View* và *Batch View*). Khung giao diện Streamlit sẽ kết nối trực tiếp vào Serving Layer để đồng bộ hóa số liệu, gộp chung với dữ liệu chuỗi thời gian của thị trường chứng khoán để hiển thị giao diện phân tích tài chính đồng nhất.

2.2 Chi tiết các công nghệ cốt lõi lựa chọn

2.2.1 Apache Kafka Cluster

Hệ thống triển khai một Kafka Broker hoàn chỉnh tích hợp Apache Zookeeper để quản lý cấu hình và đồng bộ hóa trạng thái các node phân tán. Luồng dữ liệu được định tuyến thông qua chủ đề `financial-news` được chia nhỏ thành các phân vùng để tăng cường khả năng xử lý song song.

2.2.2 Apache Spark Structured Streaming

Lỗi xử lý tính toán phân tán sử dụng kiến trúc RDD và DataFrames của PySpark. Điểm cải tiến kỹ thuật quan trọng trong luồng xử lý của hệ thống là việc cấu hình rào chắn an toàn dữ liệu `failOnDataLoss = false` nhằm triệt tiêu hoàn toàn rủi ro sập tiến trình do lệch pha chỉ mục khi hệ thống Kafka bị khởi động lại đột ngột trong môi trường thử nghiệm cục bộ.

2.2.3 MongoDB NoSQL Serving Store

Thay vì sử dụng hệ quản trị dữ liệu quan hệ truyền thống gây chậm trễ khi xử lý trường văn bản lớn, MongoDB được lựa chọn để lưu trữ các tài liệu dạng JSON linh hoạt. Hệ thống kích hoạt cơ chế ghi dữ liệu lũy đẳng ở cấp độ cơ sở dữ liệu bằng cách thiết lập một chỉ mục duy nhất (*Unique Index*) trên trường đường dẫn bài báo (*link*), ngăn chặn triệt để mọi hành vi nhân bản dữ liệu rác.

2.3 Quy trình thu thập, xử lý dữ liệu và Thiết kế tính Lũy đẳng

2.3.1 Kỹ thuật tiền xử lý dữ liệu văn bản

Tin tức cào về từ RSS Feeds thường xuyên bị dính các ký tự đặc biệt của thực thể HTML và hiện tượng lỗi font bảng mã ISO khi truyền tải qua môi trường mạng. Mã nguồn tiền xử lý chủ động giải mã thực thể bằng thư viện `html.unescape` và ép kiểu nhị phân sang định dạng UTF-8 chuẩn chỉ trước khi đưa vào hàng đợi Kafka. Trường mốc thời gian (UNIX timestamp) cũng được chuẩn hóa đồng bộ về kiểu dữ liệu `datetime` để phục vụ xếp chồng chuỗi thời gian.

2.3.2 Cơ chế Persistent Cache Warm-up chống trùng lặp đầu nguồn

Để bảo vệ tối đa tài nguyên tính toán của CPU và RAM khỏi việc phải tính toán lại các mô hình Deep Learning phức tạp cho các bài báo đã cào trong quá khứ, hệ thống xây dựng cơ chế phòng vệ 2 lớp:

1. **Lớp đầu nguồn (Producer Cache):** Mỗi khi khởi động lại, file `producer.py` tự động thực hiện một truy vấn `distinct("link")` xuống MongoDB để hút toàn bộ danh sách URL cũ nạp vào một tập hợp biến `seen_links` nằm trên RAM. Chu kỳ quét báo được đặt ở mức lý tưởng 30 phút/lần nhằm tối ưu hóa băng thông mạng.
2. **Lớp đích đến (Database Upsert):** Luồng Spark thay vì dùng lệnh chèn mù quáng đã được cấu hình sang kỹ thuật Bulk Write kết hợp toán tử `$setOnInsert` và chế độ `upsert=True`, biến mọi thao tác ghi dữ liệu lặp lại thành hành vi lũy đẳng an toàn tuyệt đối.

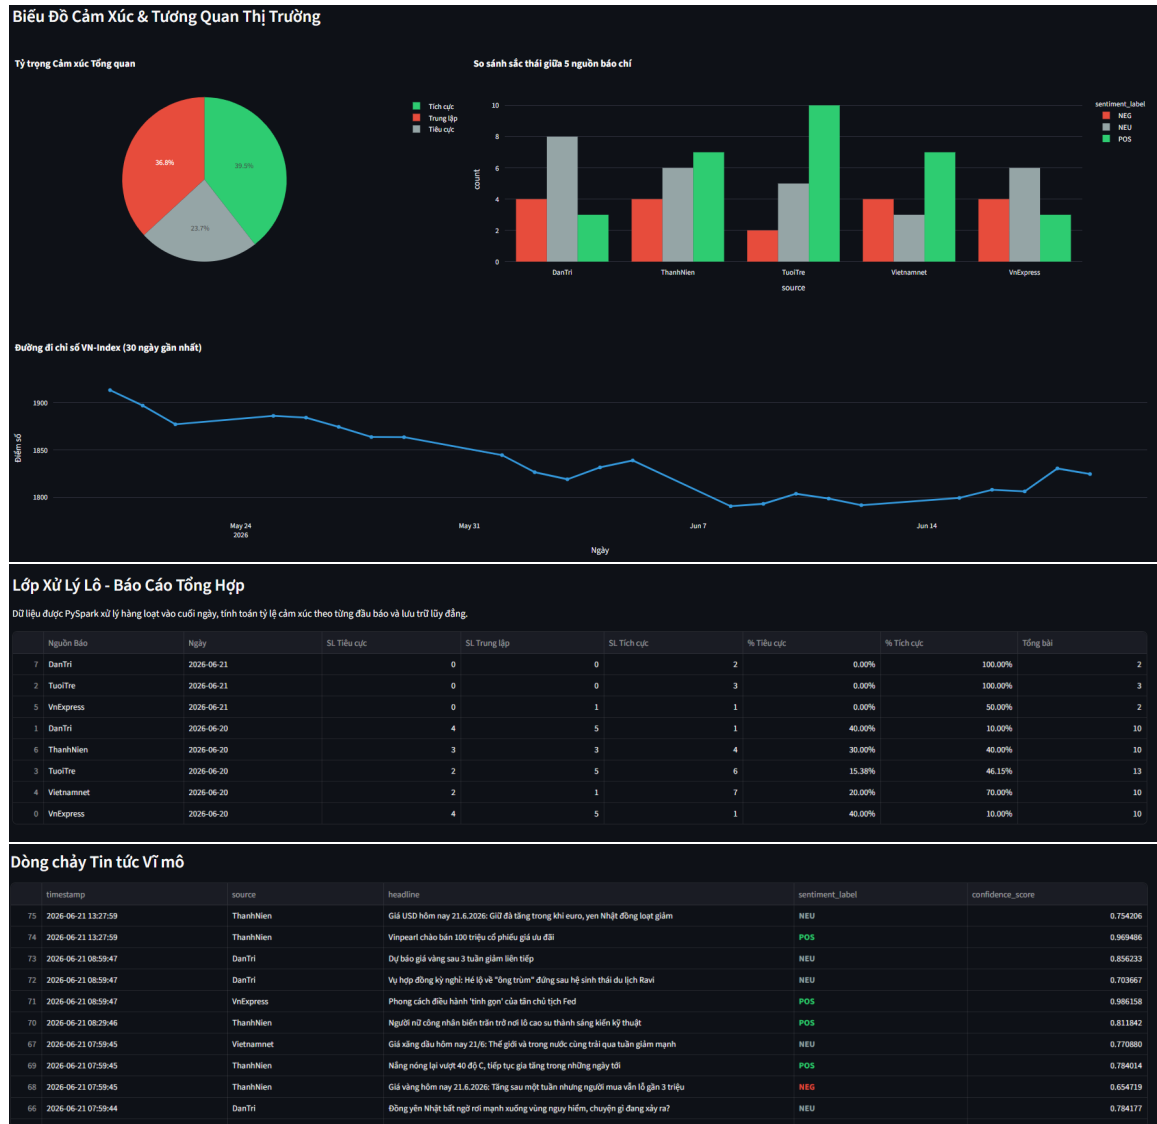
2.4 Phân tích cảm xúc bằng Mô hình Học sâu Transformer (PhoBERT)

Sắc thái cảm xúc của tiêu đề và văn bản báo chí tài chính tiếng Việt được xử lý bằng mô hình *PhoBERT-base* đã cấu hình tiền huấn luyện trên hàng tỷ câu văn bản bản địa. Pipeline nhúng mô hình trực tiếp vào kiến trúc phân tán của Spark thông qua hàm `process_batch`. Tại đây, văn bản thô được mã hóa token hóa tự động, đưa qua các lớp chú ý (Attention Layers) của Transformer để trích xuất ngữ cảnh phức tạp và trả về nhãn dự đoán kèm điểm số tin cậy (Confidence Score) một cách chính xác vượt trội so với các thuật toán học máy truyền thống.

3 CHƯƠNG 3: KẾT QUẢ VÀ HƯỚNG PHÁT TRIỂN

3.1 Giao diện Dashboard trực quan hóa tổng hợp

Giao diện người dùng được xây dựng trên nền tảng Streamlit, phân tách bộ cục khoa học thành hệ thống lưới đa tầng trực quan.



Hình 1: Giao diện Dashboard phân tích cảm xúc tin tức vĩ mô và đối chiếu chỉ số VN-Index thực tế.

Giao diện Dashboard hoàn chỉnh bao gồm 3 phân hệ cốt lõi tương ứng với kiến trúc Lambda:

- **Tầng Speed Layer (Thời gian thực):** Biểu đồ tròn biểu diễn tỷ trọng cảm xúc toàn thị trường kết hợp biểu đồ cột phân tách chi tiết xu hướng viết bài của từng tòa soạn báo chí.
- **Tầng Batch Layer (Xử lý lô dài hạn):** Bảng tổng hợp báo cáo cô đặc do PySpark

kết xuất từ bảng `daily_reports`, tính toán chi tiết tổng số bài báo và tỷ lệ phần trăm % POS, % NEG theo từng ngày cố định để theo dõi dòng chảy lịch sử.

- **Phân hệ Đối chiếu Thị trường:** Biểu đồ đường sinh động thể hiện diễn biến điểm số đóng cửa của chỉ số VN-Index trong chu kỳ 30 ngày (gọi trực tiếp từ đối tượng `Vnstock().stock().quote.history()`), đặt song song với khối lượng biến động cảm xúc để minh chứng rõ nét tư duy định lượng tài chính.

3.2 Thách thức kỹ thuật đã giải quyết

- **Khắc phục điểm nghẽn bộ nhớ vật lý (Out of Memory):** Việc nạp mô hình học sâu vào bên trong Spark JVM gây cạn kiệt tài nguyên hệ thống trên máy chủ cục bộ. Nhóm đã xử lý triệt để bằng cách giới hạn bộ nhớ nghiêm ngặt qua tham số `spark.driver.memory=1g` và mở rộng phân vùng RAM ảo (Paging File) của hệ điều hành lên mức tối đa.
- **Bảo mật môi trường Java thực thi:** Vượt qua rào cản từ chối khởi chạy tiến trình kiểm tra người dùng của Hadoop trên các phiên bản JDK đời mới bằng giải pháp can thiệp biến cấu hình hệ thống toàn cục `Djava.security.manager=allow`.

3.3 Hướng phát triển đề tài

- Đóng gói container hóa toàn diện (Dockerize) toàn bộ 4 file tiến trình độc lập thành các microservices để sẵn sàng deploy lên các hệ thống đám mây phân tán AWS hoặc Google Cloud Platform.
- Áp dụng kỹ thuật chưng cất tri thức (Knowledge Distillation) để nén nhẹ mô hình PhoBERT nhằm đẩy nhanh tốc độ xử lý micro-batch của Spark Streaming.

Tài liệu

- [1] Dat Quoc Nguyen and Anh Tuan Nguyen. *PhoBERT: Pre-trained language models for Vietnamese*. Findings of EMNLP, 2020.
- [2] Nathan Marz and James Warren. *Big Data: Principles and best practices of scalable realtime data systems*. Manning Publications, 2015.
- [3] Thinh Vu. *Vnstock3 - Python library for Vietnam stock market data generation 3*. PyPI open-source project, 2025.
- [4] Holden Karau et al. *Learning Spark: Lightning-Fast Big Data Analysis*. O'Reilly Media, 2015.